



Bashkar Station

Manual de uso y guía metodológica



Versión 12.0 · 13 de agosto de 2026

Fabián Gulla

Instituto Caro y Cuervo · Bogotá, Colombia

Sumario

PARTE I El problema antes que la herramienta

- 1 Qué tiene de difícil la prensa histórica
- 2 Qué es Bashkar Station, y qué no es
- 3 Las decisiones que conviene conocer
- 4 El corpus de referencia

PARTE II Poner en marcha

- 5 Instalar y abrir por primera vez
- 6 Tu primer corpus en veinte minutos

PARTE III Recorridos de trabajo

- 7 De la imagen al texto
- 8 Etiquetar zonas: el paso que lo cambia todo
- 9 Del texto al corpus analizable
- 10 Entidades, redes y conocimiento enlazado
- 11 Medir la calidad del reconocimiento
- 12 Publicar los resultados

PARTE IV Referencia

- 13 Los treinta paneles
- 14 Cuando algo no funciona
- 15 Glosario

El problema antes que la herramienta

Este manual no empieza explicando botones. Empieza explicando qué problema intenta resolver Bashkar Station, porque la mayoría de las decisiones de la aplicación —incluidas las que parecen incómodas— solo tienen sentido a la luz de ese problema.

① Qué tiene de difícil la prensa histórica

Una colección de prensa ilustrada de los años treinta no es un corpus de texto. Es un objeto material fotografiado, y entre la fotografía y el texto analizable hay una cadena de pérdidas que conviene mirar de frente.

El soporte llega degradado. Buena parte de la prensa colombiana del siglo XX se conserva en microfilm, y la digitalización de ese microfilm arrastra su grano, su contraste plano y la inclinación de la cámara. En el corpus de referencia de este proyecto —la revista *Estampa*, digitalizada por la Biblioteca Nacional de Colombia— las páginas llegan con entre doce y diecisiete grados de inclinación y una saturación de tinta que ronda el cuarenta por ciento.

La página no es lineal. Una revista ilustrada organiza el contenido en columnas, recuadros, pies de foto, publicidad y filetes. Un motor de OCR que lea la página de arriba abajo entrega un texto donde la primera línea de la columna izquierda se pega con la primera de la derecha. El resultado se lee como prosa rota y contamina cualquier análisis posterior.

La lengua es de otra época. El español de 1939 no es el de hoy: hay ortografía inestable, cursivas y versalitas con función semántica, extranjerismos sin adaptar, y nombres propios que ya no existen. Un lematizador entrenado con prensa contemporánea trata esas variantes como errores y las borra —borrando justo el dato que interesa al historiador de la lengua.

Los volúmenes son grandes y el tiempo es finito. Un año de una revista semanal son cincuenta números de veinte páginas. Nadie los transcribe a mano, y por eso hay que automatizar; pero automatizar sin medir el error es publicar conclusiones construidas sobre ruido.

POR QUÉ ESTO IMPORTA PARA EL RESULTADO

Cada eslabón de la cadena introduce un error que el siguiente amplifica. Un OCR con un diez por ciento de error de carácter puede parecer aceptable, pero al llegar al reconocimiento de entidades convierte «Rifa» en «Rita» y produce dos personas donde había un sorteo. La calidad del dato no es una preocupación técnica previa al análisis: **es el análisis**.

② Qué es Bashkar Station, y qué no es

Bashkar Station es una **plataforma de escritorio que orquesta la cadena completa**, desde la imagen escaneada hasta los formatos que exige una publicación académica. Reúne en un solo entorno el reconocimiento de texto, la normalización, la segmentación en artículos, el análisis lingüístico y la exportación, sin obligar a salir a la línea de comandos ni a encadenar scripts sueltos.

Conviene decir también lo que **no** es:

- **No es un framework ni una biblioteca.** Aquí no se programa. Es una herramienta de consumo y orquestación, pensada para el investigador que tiene las preguntas, no necesariamente para quien escribe el código.
- **No es un servicio en la nube.** Funciona sin conexión de principio a fin. Es una decisión deliberada, no una limitación, y el capítulo siguiente explica por qué.
- **No es una caja negra.** Cada módulo dice qué método aplica, con qué parámetros y con qué umbrales; y hay un módulo dedicado a medir cuánto se equivoca.

3 Las decisiones que conviene conocer

Cuatro decisiones de diseño explican la mayor parte del comportamiento de la aplicación. Un usuario que las entiende deja de pelearse con la herramienta.

Funciona sin conexión por defecto

La aplicación arranca con un interruptor global apagado: mientras no se active explícitamente, ninguna función llama a un servicio externo. El recorrido completo está cubierto en local —reconocimiento con Tesseract o Kraken, modelos lingüísticos de spaCy, búsqueda semántica con FAISS, y modelos de lenguaje locales a través de Ollama o LM Studio— sin coste por página.

Las interfaces de programación en la nube existen, son opcionales y exigen configurar una clave. Cuando se usan, la aplicación **estima el coste y lo muestra antes de ejecutar**, y registra el gasto real después.

NO ES UNA COMODIDAD, ES UN REQUISITO

Trabajar con prensa histórica implica material sujeto a las condiciones de uso de la institución que lo digitalizó. Que el corpus no salga del equipo salvo decisión explícita del investigador no es una preferencia técnica: es lo que permite firmar un convenio con una biblioteca.

La página es la unidad atómica

El texto se organiza por página y no por artículo continuo, porque el reconocimiento de una página escaneada no conserva información espacial suficiente para reconstruir con fiabilidad qué columna sigue a cuál. La segmentación en artículos ocurre **después**, sobre texto ya revisado, y las señales de continuación entre páginas se marcan de forma explícita.

No se lematiza por defecto

La variación ortográfica histórica es un dato lingüístico, no un error. Reducir «así» a «así» antes de analizar destruye evidencia sobre la norma escrita de la época. La lematización está disponible cuando la pregunta la requiere, pero hay que activarla a conciencia.

Se etiquetan las zonas antes de reconocer el texto

Este es el punto que más cuesta al principio y el que más rendimiento da. Antes de pasar el reconocimiento, el investigador marca sobre la imagen qué es cada región: artículo, título, pie de foto, fotografía, publicidad, filete. El motor de reconocimiento trabaja **solo sobre las zonas que llevan texto**, en el orden de lectura que se le indicó.

CUÁNTO CAMBIA ESTO, MEDIDO

Sobre una página real de *Estampa*, Tesseract aplicado a la página completa devolvió **cero palabras**. La misma página, recortada por zonas etiquetadas, devolvió **578 palabras**. El etiquetado previo no es un trámite: es lo que hace utilizable al motor rápido.

4 El corpus de referencia

Todo lo que se explica en este manual se ha probado sobre la revista *Estampa* (Bogotá, 1930-1940), un semanario ilustrado digitalizado por la Biblioteca Nacional de Colombia. Se eligió porque reúne todas las dificultades a la vez: microfilm degradado, maquetación a varias columnas con fotograbado, publicidad integrada en el cuerpo, y una lengua que ya es moderna pero conserva usos de época.

Los ejemplos y las cifras de este manual proceden de ese corpus. Cuando aparece un número medido, procede de una ejecución real y se indica sobre qué material.

Poner en marcha

Dos capítulos para pasar de no tener nada a tener un corpus analizable. El primero instala; el segundo recorre el camino completo con un solo número de revista, para que la lógica del conjunto quede clara antes de entrar en detalle.

5 Instalar y abrir por primera vez

Bashkar Station se distribuye de dos maneras, y la elección depende de si se va a programar sobre ella o solo a usarla.

Con el ejecutable (lo habitual)

Basta copiar la carpeta `BashkarStation` y hacer doble clic en `BashkarStation.exe`. No hay instalación, ni permisos de administrador, ni dependencias que resolver: todo viaja dentro, incluidos los motores de análisis.

La carpeta ocupa alrededor de 1,7 GB, así que cabe en cualquier memoria USB y funciona igual en otro equipo. El primer arranque tarda unos veinte segundos porque carga los modelos lingüísticos; los siguientes son más rápidos.

Desde el código fuente (para desarrollar)

```
git clone https://github.com/fabiangulla-pixel/Bashkar-Station.git
cd Bashkar-Station
python instalar.py
python app.py
```

`instalar.py` resuelve las dependencias de Python, descarga el modelo de spaCy para español e instala Tesseract y Poppler en Windows si faltan.

REQUISITOS REALES

Python 3.9 o superior (el desarrollo se hace sobre 3.14). Para los modelos de visión hacen falta al menos 16 GB de memoria: un modelo de tres mil millones de parámetros ocupa cerca de doce. Sin ellos, el resto de la aplicación funciona con holgura en 8 GB.

La primera pantalla

Al abrir aparece una pantalla de bienvenida con tres opciones: continuar el último proyecto, crear uno nuevo o abrir uno existente. Si se cierra sin elegir, la aplicación crea un proyecto automático para no dejar al usuario en el vacío.

Un **proyecto** es un archivo `.bashkar` más una carpeta hermana con los datos pesados. Guarda la configuración, el progreso de cada etapa y las rutas del corpus; no guarda las imágenes, que permanecen donde estén.

LAS CLAVES DE INTERFAZ DE PROGRAMACIÓN SE GUARDAN EN CLARO

Si se configuran claves de servicios de nube, quedan escritas en el archivo `.bashkar` en texto plano y en el disco. Es una limitación conocida, no un descuido: el archivo nunca sale del equipo y nunca entra al repositorio. Pero si se comparte un `.bashkar` con un colega, hay que borrar las claves antes.

6 Tu primer corpus en veinte minutos

Este recorrido usa un solo número de revista en PDF y llega hasta un texto segmentado en artículos. Es el camino corto: sirve para entender la lógica antes de afinar nada.

1 · Configurar el proyecto

En **Configuración** se indican tres cosas: el nombre de la publicación, el periodo, y la carpeta donde están los archivos de entrada. La carpeta de salida se crea sola y organiza el trabajo en subcarpetas numeradas — `01_pdfs`, `02_imagenes`, `03_ocr`, `04_analisis`, `05_etiquetas` — que se irán llenando en orden.

SI EL PDF YA TRAE TEXTO

Muchos PDF de bibliotecas digitales llevan una capa de texto de un reconocimiento previo. En ese caso, el panel ⚡ **Conversor PDF** extrae ese texto directamente y ahorra el reconocimiento entero: un número de cuarenta y ocho páginas en unos siete segundos. Merece la pena comprobarlo antes de empezar.

2 · Obtener el texto

Si no hay texto embebido, hay que reconocerlo. El panel 📄 **Extracción OCR** ofrece varias rutas y el capítulo siguiente las compara en detalle; para este primer recorrido, Tesseract con idioma español es suficiente.

3 · Revisar lo que salió

📄 **Normalizar** muestra cada página con su imagen al lado y el texto reconocido debajo. Aquí se corrige lo que el motor entendió mal. No hace falta dejarlo perfecto: el objetivo es que el texto sea lo bastante fiable para lo que se vaya a preguntar después.

La aplicación conserva tres versiones de cada página —el texto crudo, la corrección manual y la sugerencia automática— y permite elegir cuál pasa al análisis. Esa elección se guarda con el proyecto.

4 · Separar los artículos

📄 **Segmentar** detecta dónde empieza y acaba cada pieza, y distingue artículo, índice, publicidad y colofón. Aquí la unidad de trabajo deja de ser la página y pasa a ser el artículo, que es la unidad con la que razona un investigador.

5 · Analizar y exportar

Con el corpus segmentado se abre todo lo demás: frecuencias, entidades, redes, tópicos. 📄 **Resultados** exporta en los formatos que pide una publicación —TEI P5, BibTeX, hojas de cálculo— y arma un paquete completo listo para depositar.

GUARDAR ES PARTE DEL MÉTODO

La aplicación guarda sola cada tres minutos, y un punto ámbar junto al nombre del proyecto avisa cuando hay cambios sin guardar. Aun así, conviene guardar a mano antes de cualquier operación larga: la bitácora del proyecto es parte de la trazabilidad de la investigación, no solo una copia de seguridad.

Recorridos de trabajo

Cada capítulo de esta parte resuelve una tarea completa, de principio a fin. No hace falta leerlos en orden: se puede ir al que corresponda al problema que se tenga delante.

⑦ De la imagen al texto

Reconocer texto sobre prensa histórica no es un problema resuelto, y por eso la aplicación no ofrece un botón sino **siete rutas**. Elegir bien ahorra semanas.

Las rutas disponibles

Ruta	Cómo funciona	Cuándo conviene
Tesseract	Motor clásico, local, muy rápido	Impresos limpios, o cualquier página ya etiquetada por zonas
Tesseract por zonas	Recorta cada zona, la mejora y la reconoce aparte	Maquetación a varias columnas; es la ruta por defecto recomendada
Texto embebido (BNC)	Extrae la capa de texto del PDF y reconstruye el orden por coordenadas	PDF de biblioteca con reconocimiento previo
Kraken / CATMuS	Modelo entrenado para impresos históricos	Tipografías antiguas donde Tesseract falla
IA de visión en la nube	Claude, GPT o Gemini leen la imagen	Páginas irrecuperables, cuando el presupuesto lo permite
CHURRO-3B	Modelo de visión de pesos abiertos, local y gratuito	Lo mismo que el anterior, sin coste ni salida de datos
PERO-OCR	Cadena especializada en prensa desde microfilm	El caso típico de las hemerotecas latinoamericanas

Cómo elegir sin adivinar

La respuesta corta: **midiendo**. El capítulo «Medir la calidad del reconocimiento» explica cómo, y es el que convierte esta elección en una decisión defendible ante un evaluador.

La respuesta larga tiene una regla práctica que se sostiene en datos medidos sobre *Estampa*:

DOS MEDICIONES SOBRE EL MISMO CORPUS

Sobre una página completa sin etiquetar, Tesseract devolvió **0 palabras** y CHURRO-3B **499**, en 51 minutos de proceso.

Sobre una página etiquetada por zonas, Tesseract devolvió **578** palabras en 11 segundos y CHURRO **569** en 38 minutos.

La lectura: **el etiquetado rescata al motor rápido**, y el modelo de visión es la herramienta para lo que ni así se recupera —o para construir la referencia con la que se mide todo lo demás.

EL RECuento DE PALABRAS NO MIDE LA CALIDAD

En esa segunda medición las dos rutas produjeron casi las mismas palabras, pero Tesseract escribió «Rita» donde decía «Rifa», «Esta maqgnilica» donde decía «Esta magnífica» y «s 75 00» donde decía «\$ 75.00», además de inventar líneas enteras. Para un recuento de frecuencias eso es ruido; para el reconocimiento de entidades, «Rita» y «Rifa» son cosas distintas. Contar palabras no basta: hay que medir el error de carácter.

Usar CHURRO-3B

Es un modelo de pesos abiertos entrenado sobre casi cien mil páginas históricas de ciento cincuenta y cinco colecciones, veintidós siglos y cuarenta y seis grupos lingüísticos —el español entre ellos—. Corre en el equipo, no cuesta dinero y no saca el corpus fuera.

Pesa unos siete gigabytes que se descargan una sola vez desde el propio panel de  **Benchmark OCR**, con el botón *Descargar modelo CHURRO*. Después funciona sin conexión. Si se coloca la carpeta del modelo en `modelos_ia`, junto al ejecutable, viaja con la aplicación en la memoria USB.

ES LENTO, Y HAY QUE CONTAR CON ELLO

Entre tres y cuatro minutos por zona en un procesador de seis núcleos sin tarjeta gráfica. Sirve para construir una referencia de calidad sobre unas decenas de zonas, no para procesar un corpus entero. La aplicación estima el tiempo y pide confirmación antes de lanzar un lote.

8 Etiquetar zonas: el paso que lo cambia todo

Es el capítulo más importante de este manual. El etiquetado parece trabajo manual prescindible y es justo lo contrario: es lo que hace que el resto funcione.

Qué se hace

En  **Etiquetar** se dibujan rectángulos sobre la imagen de la página y se asigna a cada uno un tipo. Los tipos que llevan texto —artículo, título, pie de foto, índice— se reconocen; los que no —fotografía, publicidad, filete, cabecera, colofón, número de página— se saltan.

Por qué importa tanto

Tres razones, y las tres tienen consecuencias medibles:

1. **Preserva el orden de lectura.** Un motor que lee la página entera mezcla las columnas. Uno que lee zona por zona, en el orden que se le indicó, entrega prosa continua.
2. **Evita el ruido.** Una fotografía no contiene texto que interese, pero un motor de reconocimiento intentará leerla igual y devolverá basura que luego contamina las frecuencias.
3. **Ahorra recursos.** Con un modelo de visión, cada zona que no se procesa son miles de unidades de cómputo que no se gastan. Y evita que el modelo se ponga a describir la imagen en lugar de transcribirla.

EL ORDEN DE LECTURA ES UNA DECISIÓN EDITORIAL

La aplicación calcula un orden automático por bandas y columnas, pero se puede corregir a mano. Ese orden es una interpretación de la maquetación, y en publicaciones con recuadros o continuaciones puede haber más de una lectura razonable. Conviene dejar constancia del criterio en la bitácora del proyecto.

Ayudas para no hacerlo todo a mano

Hay detección automática de zonas —por análisis de imagen o por inteligencia artificial de visión— que propone un etiquetado inicial. Es un punto de partida, no un resultado: siempre conviene revisarlo. También se pueden dividir y fusionar zonas, y vincular un pie de foto con su fotografía.

9 Del texto al corpus analizable

Normalizar sin destruir

 **Normalizar** es donde el texto reconocido se convierte en texto fiable. La pantalla muestra la imagen y el texto, y permite corregir palabra por palabra.

El verificador señala las palabras dudosas y propone alternativas del diccionario y del propio corpus. Se puede ampliar el vocabulario con los nombres propios y los términos de época que la revista usa y ningún diccionario recoge.

NORMALIZAR NO ES MODERNIZAR

La normalización de esta aplicación es deliberadamente conservadora: limpia artefactos del reconocimiento, no la ortografía de la época. Si el original escribe «obscuró», se queda «obscuró». Modernizar aquí destruiría el dato que busca el historiador de la lengua.

Segmentar en artículos

 **Segmentar** localiza dónde empieza y acaba cada pieza y le asigna una tipología. A partir de aquí la unidad de análisis es el artículo, que es como razona el investigador, y no la página, que es como llegó el material.

Las continuaciones entre páginas se marcan de forma explícita, porque adivinarlas automáticamente produce errores silenciosos difíciles de detectar después.

10 Entidades, redes y conocimiento enlazado

Reconocer entidades

🔍 **Entidades** identifica personas, lugares, organizaciones, fechas, obras y eventos. Combina tres métodos: un modelo estadístico de spaCy, un modelo neuronal específico para español, y opcionalmente un modelo de lenguaje que valida los casos dudosos.

Cada entidad recibe un semáforo de confianza. 🔍 **Revisión NER**, dentro del panel de Lingüística, presenta una cola con las dudosas para confirmarlas, descartarlas o renombrarlas. Las decisiones quedan registradas y se aplican al índice global.

POR QUÉ HAY REVISIÓN HUMANA

Ninguna combinación de modelos alcanza precisión suficiente sobre texto histórico degradado. Una cola de revisión con trazabilidad no es una concesión: es lo que permite escribir en el artículo cuántas entidades se validaron a mano y con qué criterio.

Enlazar con Wikidata

Las entidades se pueden vincular a Wikidata, lo que las convierte en identificadores globales citables. La desambiguación tiene en cuenta el contexto del artículo, filtra por tipo de entidad y descarta homónimos modernos fuera de la ventana histórica.

LO QUE COSTÓ AFINARLO

En una primera versión, cinco de cada siete entidades del corpus se enlazaban mal: «Francisco Franco» apuntaba a un tenista colombiano y «España» a un acorazado de 1912. Con la desambiguación actual, seis de siete son correctas. El caso que resiste es «Alfonso López», presidente colombiano de los años treinta, que Wikidata no distingue sin contexto adicional.

Construir la red

🏰 **Redes** construye el grafo de entidades que aparecen juntas, calcula métricas de centralidad y detecta comunidades. Exporta a GEXF para trabajar en Gephi.

UNA RED DE AUTORES NO SIEMPRE TIENE SENTIDO

En *Estampa*, el 74 % de los artículos son anónimos. Una red de coautoría sobre ese material no mide colaboración: mide coincidencia en el mismo número, que es trivial. Por eso la red se construye sobre entidades mencionadas y no sobre firmas. Conviene comprobar este tipo de supuestos antes de graficar.

11 Medir la calidad del reconocimiento

Este capítulo describe el módulo que convierte «elegí este motor» en «medí los motores y elegí este».

Por qué hace falta

Elegir una ruta de reconocimiento porque «se ve mejor» no es defendible en una publicación. ⚖️ **Benchmark OCR** transcribe las mismas páginas con varias rutas y las compara contra una transcripción de referencia hecha a mano.

Las métricas

Métrica	Qué mide	Cómo leerla
CER	Proporción de caracteres a corregir	$\leq 0,05$ casi limpio · $\leq 0,10$ explotable · $\leq 0,25$ exige corrección · $> 0,25$ inservible
WER	Lo mismo por palabras	Siempre mayor que el CER: un carácter mal invalida la palabra entera
Similitud	$1 - \text{CER}$	Comparable con la literatura publicada
Segundos por página	Coste en tiempo	Decide qué ruta sirve para el corpus completo y cuál solo para la muestra

Construir el estándar de oro

Sin transcripción de referencia solo se pueden comparar rutas entre sí. El CER absoluto exige que alguien transcriba a mano, y la aplicación reduce ese trabajo al mínimo.

El botón  **Preparar estándar de oro** exporta **un recorte por zona con texto**, cada uno con su archivo de texto vacío al lado. Se transcriben bloques cortos, no páginas enteras: se puede parar y seguir, y el botón  **Avance** dice cuánto queda.

Las reglas de transcripción van en un archivo de instrucciones dentro de la propia carpeta. La primera es la que más se incumple: **transcribir lo que se ve, no lo que debería decir**. Si el original escribe «Kadet» con una sola te, se transcribe «Kadet». El estándar mide al motor, no corrige a la revista.

SOBRE RELLENAR PREVIAMENTE CON EL RESULTADO AUTOMÁTICO

La aplicación permite volcar la salida de un motor para corregirla en lugar de escribir desde cero. Ahorra mucho tiempo y es práctica habitual, pero **sesga**: quien corrige tiende a dar por buenos los errores que no saltan a la vista. Y si el estándar se usa después para evaluar ese mismo motor, la comparación queda invalidada. Por eso viene desactivado y, cuando se usa, queda registrado.

Interpretar el resultado

La tabla se exporta a hoja de cálculo o se copia como tabla lista para pegar en un artículo. Lo habitual es que ninguna ruta gane en todo: una es exacta y lenta, otra rápida y sucia. La decisión razonable suele ser **usar la lenta y buena para construir la referencia, y la rápida para el corpus completo**, documentando el error que se acepta.

12 Publicar los resultados

Formatos de intercambio

 **Resultados** exporta en TEI P5 —el estándar de codificación de textos en humanidades, con las entidades en su sección correspondiente—, en BibTeX para gestores bibliográficos, y en hojas de cálculo para análisis estadístico posterior.

También genera un **paquete de publicación** completo: la codificación, las referencias, las tablas, la bitácora de investigación y un documento de métodos con los parámetros usados en cada etapa.

El bundle de conocimiento abierto

El exportador OKF produce un directorio de archivos de texto con metadatos, sin depender de una base de datos ni de una interfaz propia. Está pensado para que cualquier sistema —incluidos los asistentes de inteligencia artificial— pueda leer el conocimiento del corpus directamente.

Obtener un identificador citable

El repositorio del proyecto puede conectarse a Zenodo, de modo que cada versión publicada genere automáticamente un identificador digital permanente. Es el requisito que suelen pedir las revistas de humanidades digitales para citar el software con el que se produjo un análisis.

LA REPRODUCIBILIDAD ES PARTE DEL RESULTADO

Un análisis computacional que no puede repetirse no es un resultado, es una anécdota. Guardar la bitácora, exportar el documento de métodos y depositar el software con identificador permanente son los tres gestos que convierten un trabajo en algo que otro investigador puede verificar.

Referencia

Las fichas de los treinta paneles, la solución de los problemas más frecuentes y un glosario. Esta parte está pensada para consultarla, no para leerla seguida.

13 Los treinta paneles

Las fichas que siguen **se generan desde el código fuente de la aplicación**, del mismo archivo que alimenta la ayuda que aparece dentro de cada panel. Por eso el manual no puede contradecir a la interfaz: si una guía cambia en el programa, cambia aquí al regenerar el documento.

Cada ficha responde a cuatro preguntas: qué es, para qué sirve, qué resultado produce y cómo interpretar ese resultado. La última es la más útil, porque incluye los umbrales y las trampas de cada método.

El punto de partida

La pantalla con la que abre la aplicación: resume el estado del proyecto y desde ahí se entra a todo lo demás.

△ Inicio

Panel de investigación

QUÉ ES

Tablero de investigación: la primera pantalla al abrir la aplicación. Resume en una sola vista el proyecto activo, cuánto corpus hay procesado y en qué etapa va el flujo.

PARA QUÉ SIRVE

Retomar el trabajo sin tener que recorrer los paneles para averiguar qué quedó a medias, y comprobar de un vistazo qué motores locales están disponibles en este equipo antes de lanzar un proceso largo.

QUÉ RESULTADO DA

Cuatro indicadores del corpus (páginas procesadas, confianza media del OCR, artículos segmentados y entidades reconocidas), el estado de las seis etapas del flujo, las acciones sugeridas y la lista de capacidades instaladas. No calcula nada nuevo: lee el estado del proyecto en memoria.

CÓMO INTERPRETARLO

La confianza media del OCR es el número que decide si vale la pena seguir: por debajo de ~60 conviene revisar el etiquetado de zonas o cambiar de ruta de extracción antes de segmentar, porque todo el análisis textual hereda esos errores. Una etapa en ámbar («revisar») no significa que falle, sino que se completó y después cambió una etapa anterior: los resultados que muestre están calculados sobre material viejo. La pastilla «IA externa» de la barra superior dice si algún módulo puede enviar texto a un tercero; apagada, el procesamiento es íntegramente local.

El flujo principal

Los paneles que se recorren en orden para llevar un corpus desde las imágenes hasta el texto analizable.

⚙ Configuración

Configuración del corpus

QUÉ ES

Punto de partida del proyecto: define el corpus (carpetas de imágenes/PDF), las claves de API y el modelo de IA que usará cada etapa del análisis.

PARA QUÉ SIRVE

Dejar reproducible de dónde sale el material y con qué herramientas se procesa. Es la base de la trazabilidad metodológica que exige una revista.

QUÉ RESULTADO DA

Un proyecto .bashkar con rutas, claves y preferencias persistentes. No produce análisis todavía.

CÓMO INTERPRETARLO

No hay cifras que interpretar aquí, pero sí decisiones que documentar en el paper: qué proveedor de IA se usó (local Ollama vs. nube), qué modelo y por qué. El modelo elegido afecta costo, privacidad (los datos salen a un tercero salvo Ollama) y reproducibilidad (los modelos de nube cambian con el tiempo; anota la fecha y la versión). Para corpus histórico en español, los modelos grandes de visión (Gemini/Claude/GPT) superan a Tesseract en microfilm degradado.



Etiquetar

Etiquetar zonas de página (opcional)

QUÉ ES

Editor manual de zonas: marcas sobre la imagen qué región es título, cuerpo, foto, pie, publicidad o filete, y en qué orden de lectura van.

PARA QUÉ SIRVE

Enseñar al OCR la estructura de la página (prensa ilustrada multicolumna) para que el texto salga en orden y sin mezclar columnas ni pies de foto con el cuerpo.

QUÉ RESULTADO DA

Un mapa de zonas con tipo y orden, que alimenta el OCR por regiones y la segmentación posterior.

CÓMO INTERPRETARLO

El orden de lectura es lo crítico: si los badges de orden saltan de columna incorrectamente, el texto OCR saldrá desordenado y contaminará todo el análisis textual aguas abajo. Revisa que las fotos estén marcadas como tales (su 'texto' OCR es ruido) y que los pies de foto NO se fundan con el cuerpo del artículo. En layouts tipo 'marco' (texto rodeando una ilustración) el orden automático suele fallar: corrígelo a mano. Una buena zonificación es la diferencia entre un corpus limpio y uno irrecuperable.



Extracción OCR

Extracción de texto por OCR

QUÉ ES

Reconocimiento óptico de caracteres: convierte la imagen de cada página en texto editable, por varias rutas (Tesseract local, IA de visión, Kraken/HTR, texto embebido).

PARA QUÉ SIRVE

Obtener el texto del corpus, materia prima de todo el análisis. Sin texto fiable no hay NER, ni tópicos, ni sentimiento que valgan.

QUÉ RESULTADO DA

Archivos de texto por página, con un índice de confianza del reconocimiento.

CÓMO INTERPRETARLO

Vigila la CONFIANZA: páginas por debajo de ~30 % suelen estar tan degradadas que su texto es ruido (palabras partidas, 'pofftica' por 'política'). El microfilm de la BNC con grano e inclinación da 0 palabras útiles en Tesseract sin skew+denoise; ahí conviene la ruta de IA de visión. Regla de oro de HD: la calidad del OCR pone el techo a TODO el análisis posterior. Antes de sacar conclusiones, mide la tasa de error sobre una muestra transcrita a mano (CER/WER) y repórtala — es el dato que una revista te va a pedir para confiar en el resto.

Conversor PDF

Conversión masiva PDF→Word/TXT (texto embebido)

QUÉ ES

Conversor masivo de PDF a texto/Word extrayendo el texto YA embebido (PDFs con capa OCR previa, p. ej. Adobe Paper Capture de la BNC), sin reconocer.

PARA QUÉ SIRVE

Aprovechar OCR ya hecho: rapidísimo (48 págs en segundos) y sin costo, cuando el PDF trae texto detrás de la imagen.

QUÉ RESULTADO DA

Archivos .txt/.docx por página, limpios de coordenadas XY del OCR de origen, listos para Normalizar.

CÓMO INTERPRETARLO

Útil sólo si el PDF tiene capa de texto: si el conversor saca poco o nada, el PDF es imagen pura y necesitas la ruta de OCR/IA. El texto embebido de la BNC suele ser de calidad media (OCR antiguo): trátalo como punto de partida a revisar en Normalizar, no como verdad final. Conserva nota de la procedencia (OCR de origen vs. propio) porque mezclar OCR de distinta calidad introduce sesgos difíciles de rastrear después.

Extracción IA

Extracción multimodal estructurada de imágenes (IA de visión → JSON → .md)

QUÉ ES

Extracción multimodal con IA de visión: la IA 'lee' la página y devuelve su estructura en JSON (artículo jerárquico, fotos con sus pies, bloques de publicidad), no sólo texto plano.

PARA QUÉ SIRVE

Rescatar páginas que el OCR clásico no recupera (microfilm degradado) Y obtener de una vez la estructura editorial, separando cuerpo, pies de foto y anuncios.

QUÉ RESULTADO DA

Un JSON por página + Markdown legible; alimenta el corpus textual con el cuerpo del artículo (excluyendo pies y publicidad) y registra el costo real de IA.

CÓMO INTERPRETARLO

La gran ventaja sobre el OCR plano es que la salida viene ya SEPARADA por función editorial: el cuerpo del artículo no se contamina con texto de anuncios. Pero la IA de visión puede 'alucinar' (inventar texto plausible donde no lo lee); por eso conserva la ortografía de época y DEBES validar una muestra contra la imagen original. Estima siempre el costo antes de lanzar el lote (se muestra el desglose tokens/USD) y registra el costo real post-lote: es parte del estándar de transparencia. Para el paper, reporta proveedor, modelo y fecha: estos modelos evolucionan y el resultado no es perfectamente reproducible.

Normalizar

Revisión y normalización del texto

QUÉ ES

Revisión y normalización del texto OCR: corriges errores, eliges entre versiones (cruda / manual / IA), y comparas diferencias antes de fijar el texto definitivo.

PARA QUÉ SIRVE

Producir la versión del texto sobre la que correrá el análisis, decidiendo cuánto normalizar sin borrar rasgos históricos que son objeto de estudio.

QUÉ RESULTADO DA

El texto 'de trabajo' del corpus, versionado y persistente, más un diccionario de corpus opcional.

CÓMO INTERPRETARLO

Decisión metodológica central: ¿normalizas la ortografía de época (p. ej. acentuación antigua) o la conservas? Si tu objeto de estudio ES la lengua de los años 30, normalizar de más BORRA tu evidencia. Si te interesa el contenido (temas, actores), normalizar ayuda a que NER y tópicos agrupen variantes. Documenta qué criterio usaste y aplícalo de forma consistente a todo el corpus. El diff visual rojo/verde te muestra el impacto de cada cambio: úsalo para no introducir errores nuevos al 'corregir'.



Segmentar

Segmentación en artículos

QUÉ ES

Segmentación: parte el texto continuo de cada número en artículos individuales y los tipifica (artículo, índice, publicidad, portada, colofón).

PARA QUÉ SIRVE

Convertir un flujo de páginas en unidades de análisis (el artículo), que es lo que se cuenta, compara y clasifica en el resto del estudio.

QUÉ RESULTADO DA

Una lista de artículos con su tipo, longitud y texto, base de todos los análisis por documento.

CÓMO INTERPRETARLO

La unidad de análisis condiciona todo: si la segmentación une dos artículos, sus temas y entidades se mezclan; si parte uno en dos, infla los conteos.

Revisa que los textos muy cortos (<20 palabras) no estén inflando la categoría 'Portada' por diseño del clasificador. Comprueba el reparto de tipos: un corpus de prensa ilustrada con 0 % de publicidad detectada es sospechoso. El recuento de artículos por número y por tipo es un dato descriptivo que conviene reportar como primera caracterización del corpus.



Analizar

Análisis textual y semántico

QUÉ ES

Análisis textual y semántico de base: frecuencias, n-gramas, palabras clave, y expansión semántica con Word2Vec entrenado sobre tu propio corpus.

PARA QUÉ SIRVE

Una primera lectura cuantitativa del vocabulario: qué se nombra mucho, qué palabras aparecen juntas, qué campos semánticos estructura el corpus.

QUÉ RESULTADO DA

Tablas de frecuencias y n-gramas, y vecinos semánticos por palabra (p. ej. guerra → hitlerianos, mujer → modas).

CÓMO INTERPRETARLO

Las frecuencias crudas están dominadas por palabras vacías y por el RUIDO de OCR: filtra stopwords y fragmentos antes de concluir nada. Los n-gramas (bigramas/trigramas) revelan fórmulas y colocaciones de la época. En la expansión semántica (Word2Vec), los 'vecinos' reflejan co-aparición en contextos similares, NO sinonimia ni causalidad: que 'guerra' y 'hitlerianos' estén próximos describe el discurso de 1939, no una opinión. Vecinos raros ('túon', 'pofftica') son síntoma de OCR sucio, no hallazgos. Necesitas suficiente corpus (miles de palabras) para que los vectores sean estables.



Resultados

Resultados y exportación

QUÉ ES

Centro de resultados y exportación: reúne las salidas del proyecto y las empaqueta en formatos estándar (TEI, BibTeX, CSV, Markdown, ZIP de publicación).

PARA QUÉ SIRVE

Sacar el material del programa hacia el paper, el repositorio de datos (Zenodo/DOI) y otras herramientas.

QUÉ RESULTADO DA

Ficheros estándar interoperables y un paquete de publicación reproducible.

CÓMO INTERPRETARLO

No interpretas cifras aquí, sino que garantizas interoperabilidad: el TEI P5 permite que otros humanistas reusen tu corpus; el BibTeX cita las fuentes; el CSV (utf-8-sig) abre bien en Excel español. Antes de publicar, valida el TEI (debe dar 0 errores) y revisa que los identificadores sean estables. Publicar el paquete con DOI es lo que convierte tu software y tus datos en un objeto citable y reproducible.

Análisis

Herramientas que se aplican sobre el corpus ya segmentado. Ninguna es obligatoria: se eligen según la pregunta de investigación.

Entidades

Índice de entidades nombradas

QUÉ ES

Reconocimiento de Entidades Nombradas (NER): detecta y clasifica personas, lugares y organizaciones en el texto, combinando spaCy, un modelo BERT y opcionalmente un LLM.

PARA QUÉ SIRVE

Saber QUIÉN, DÓNDE y QUÉ instituciones aparecen en el corpus y con qué frecuencia: el insumo de las redes de actores, los mapas y el grafo de conocimiento.

QUÉ RESULTADO DA

Un índice de entidades por categoría con su frecuencia y los artículos donde aparecen; exportable a CSV y enlazable a Wikidata.

CÓMO INTERPRETARLO

El NER sobre OCR histórico tiene falsos positivos (fragmentos OCR tomados por nombres) y falsos negativos (nombres mal escritos no reconocidos). Una misma persona aparece como variantes ('López', 'Alfonso López'); por eso existe la fusión canónica y la cola de revisión human-in-the-loop. NO leas la frecuencia como 'importancia' sin más: depende de la cobertura del corpus. Si vas a construir redes, guarda TODAS las entidades por artículo (no sólo la principal), o la red saldrá trivial. Reporta precisión/recall sobre una muestra anotada a mano: es la validación que da credibilidad al análisis de actores.



Anotar

Anotación semántica revisable

QUÉ ES

Anotación semántica revisable estilo Recogito: marcas pasajes con etiquetas, registrando QUIÉN lo anotó, con qué confianza y con historial de cambios (Assertive Edition).

PARA QUÉ SIRVE

Construir interpretación trazable: cada afirmación sobre el texto queda con su procedencia, lista para auditar o discutir entre codificadores.

QUÉ RESULTADO DA

Anotaciones con fuente, confianza e historial, exportables como Web Annotation (JSON-LD).

CÓMO INTERPRETARLO

La clave epistemológica es la PROCEDENCIA: una anotación no es un hecho, es una aserción de alguien con un grado de certeza. Aprovecha la confianza para distinguir lo seguro de lo conjetural, y el historial para mostrar cómo evolucionó tu lectura. En equipo, las discrepancias entre anotadores no son errores a esconder: son datos sobre la ambigüedad del material, y se cuantifican con el módulo de Validación (Kappa).



Búsqueda

Búsqueda semántica por similitud

QUÉ ES

Búsqueda semántica por similitud: encuentra pasajes parecidos en SIGNIFICADO a una consulta, usando embeddings (sentence-transformers + FAISS), no coincidencia exacta de palabras.

PARA QUÉ SIRVE

Localizar de qué se habla aunque no se usen tus palabras exactas: recuperar el tratamiento de un tema disperso en el corpus con distinto vocabulario.

QUÉ RESULTADO DA

Una lista de pasajes ordenados por similitud semántica con un puntaje (0–1).

CÓMO INTERPRETARLO

El puntaje mide cercanía en el espacio vectorial, no verdad ni relevancia: un valor alto significa 'parecido en uso', y puede traer falsos amigos. Es una herramienta de EXPLORACIÓN y recuperación, no de medición: úsala para encontrar material, luego lee los pasajes. Los modelos de embeddings se entrenaron en español moderno, así que en lengua de 1930 pueden perder matices. No reportes 'similitud 0.82' como hallazgo; repórtalo como criterio con el que reuniste un conjunto de pasajes que luego analizaste cualitativamente.



Collocates

Redes léxicas y concordancias

QUÉ ES

Collocates y concordancias: muestra qué palabras acompañan habitualmente a un término (su vecindario léxico) y en qué contextos aparece (líneas KWIC).

PARA QUÉ SIRVE

Estudiar el USO de una palabra: con qué se asocia 'mujer', 'guerra' o 'moderno' en la prensa de la época —la base de la lingüística de corpus.

QUÉ RESULTADO DA

Tablas de colocados con medidas de asociación y concordancias palabra-en-contexto.

CÓMO INTERPRETARLO

Las medidas de asociación (p. ej. información mutua) premian co-apariciones **DISTINTIVAS**, no sólo frecuentes: un colocado raro pero muy ligado puede ser más revelador que uno común. Cuidado con la frecuencia mínima: con pocos casos, la asociación es inestable (azar). La ventana (cuántas palabras a cada lado) cambia el resultado: ventanas cortas captan sintaxis, largas captan temática. Las concordancias KWIC son la prueba cualitativa: siempre vuelve al texto real antes de afirmar que dos términos 'van juntos'.



Novedad

Detección de novedad y cambio discursivo

QUÉ ES

Detección de novedad y cambio discursivo: identifica cuándo aparecen temas o vocabulario **NUEVOS** respecto a lo anterior en la secuencia temporal del corpus.

PARA QUÉ SIRVE

Detectar inflexiones: el momento en que el discurso de la revista cambia de foco (irrupción de un tema, giro de tono), útil para periodizar.

QUÉ RESULTADO DA

Una curva/serie de novedad por número o fecha, marcando los picos de cambio.

CÓMO INTERPRETARLO

Un pico de novedad señala que ESE número introduce léxico/temas poco vistos antes; es una pista, no una explicación: hay que ir al material y ver qué pasó (un acontecimiento histórico, un cambio editorial). Distingue novedad real de artefactos: un cambio de OCR o de fuente puede simular 'novedad' léxica. Con pocos números el cálculo es ruidoso. Es ideal para **CONTAR** una historia cronológica en el paper, anclando cada pico a evidencia textual concreta.

Redes

Redes de co-ocurrencia

QUÉ ES

Redes de co-ocurrencia: construye un grafo donde los nodos son entidades (o palabras) y las aristas indican que aparecen juntas; calcula comunidades y métricas.

PARA QUÉ SIRVE

Ver la ESTRUCTURA relacional del corpus: qué actores y lugares forman bloques, quién es central, cómo se agrupan los temas.

QUÉ RESULTADO DA

Un grafo (visual y exportable a GEXF/Gephi) con comunidades coloreadas y métricas: grado, centralidad, modularidad, densidad.

CÓMO INTERPRETARLO

Las métricas tienen umbrales de referencia: la MODULARIDAD $> 0.3-0.4$ indica que las comunidades detectadas son reales y no azar (en este corpus se obtuvo ~ 0.57 , comunidades coherentes: guerra-España, bloque anglosajón, Europa). La CENTRALIDAD señala nodos puente, no necesariamente importancia histórica. Cuidado: co-ocurrir en un mismo número/artículo NO es relación social ni causal — es co-presencia textual. La densidad y el tamaño dependen de cuántas entidades guardaste por documento: si la base trae ~ 1 entidad/artículo, la red será pobre (hace falta re-NER guardando todas). Reporta el método de construcción (qué cuenta como arista) o la red no será interpretable por otros.



Lingüística

Sintaxis, correferencia, morfología, encuadre, polaridad, revisión NER y validación

QUÉ ES

Suite de lingüística computacional: sintaxis (dependencias, SVO), correferencia, morfología histórica, encuadre (framing), polaridad y validación inter-codificador.

PARA QUÉ SIRVE

Pasar del QUÉ se dice al CÓMO se dice y desde qué ÁNGULO: estructura de las frases, arcaísmos, marcos interpretativos y tono hacia actores concretos.

QUÉ RESULTADO DA

Tablas por artículo de relaciones SVO, cadenas de correferencia, densidad de arcaísmos, frame dominante, polaridad y, en Validación, el Kappa de concordancia.

CÓMO INTERPRETARLO

ENCUADRE (framing): clasifica cada artículo por el ÁNGULO (guerra, modernidad, mujer, nación...), no por el tema literal; el frame 'dominante' es el de mayor léxico, pero un texto puede combinar varios. POLARIDAD: pos/neg/neutro discriminante, mejor que el sesgo a 'confianza' del modelo de 8 emociones; 'polaridad hacia X' mide el tono en una ventana alrededor de la entidad, sin cruzar de un artículo a otro. MORFOLOGÍA HISTÓRICA: una densidad de arcaísmos baja (~0.6 %) indica español ya moderno en 1939, hallazgo en sí mismo. VALIDACIÓN: el Kappa de Cohen mide acuerdo entre tu etiquetado automático y uno humano sobre una muestra; >0.6 es aceptable, >0.8 bueno. Reportar Kappa es la defensa de fiabilidad que una revista exige antes de creer en cualquier clasificación automática.



Semántico

Tono, léxico y estilo

QUÉ ES

Análisis semántico de tono, léxico y estilo: emociones (NRC), subjetividad, intensidad y rasgos estilométricos del texto.

PARA QUÉ SIRVE

Caracterizar el registro de la prensa: ¿es sobrio o exaltado?, ¿factual u opinativo?, ¿qué emociones predominan en su retórica?

QUÉ RESULTADO DA

Perfiles de emoción (8 categorías), índices de subjetividad/intensidad y métricas de estilo por artículo o corpus.

CÓMO INTERPRETARLO

El léxico de emociones NRC tiende a sobre-representar 'confianza' (palabras neutras que el diccionario marca como positivas): por eso para polaridad pura conviene el módulo discriminante de Lingüística. Lee el perfil emocional como RETÓRICA del texto, no como la emoción del autor ni del lector. La subjetividad alta marca opinión/editorial; la baja, registro informativo. Estos diccionarios se calibraron en lengua moderna: en 1930 algunos términos tenían otra carga, así que valida una muestra. Un perfil 'sobrio, dominado por confianza' es un hallazgo defendible sobre el ESTILO de la publicación.

Tópicos

Topic modeling del corpus

QUÉ ES

Topic modeling: descubre automáticamente los TEMAS latentes del corpus agrupando palabras que tienden a aparecer juntas (NMF/BERTopic).

PARA QUÉ SIRVE

Obtener un mapa temático del corpus sin leerlo entero: qué grandes asuntos lo organizan y cómo se distribuyen entre números.

QUÉ RESULTADO DA

Una lista de tópicos, cada uno descrito por sus palabras más representativas, y el peso de cada tópico por documento.

CÓMO INTERPRETARLO

Los tópicos son agrupaciones ESTADÍSTICAS de palabras, no categorías predefinidas: tú les pones nombre leyendo sus términos principales, y ese paso es interpretativo. El número de tópicos es una decisión tuya: pocos = temas vagos, muchos = temas redundantes/ruidosos; pruébalo y justifícalo. Un tópico dominado por fragmentos de OCR es basura, no un tema. La coherencia del tópico (¿sus palabras 'cuelgan juntas' para un humano?) importa más que cualquier métrica automática. Reporta cómo elegiste el número de tópicos y qué nombre les diste: sin eso, el modelo no es replicable.

Visualizar

Visualizaciones avanzadas

QUÉ ES

Visualizaciones avanzadas: nubes de palabras limpias, mapas de calor temporales, redes y gráficos comparativos del corpus.

PARA QUÉ SIRVE

Comunicar patrones de un vistazo y explorar el corpus visualmente, tanto para tu propio análisis como para las figuras del paper.

QUÉ RESULTADO DA

Figuras (PNG/HTML) listas para incrustar: nubes, heatmaps, redes, comparativas.

CÓMO INTERPRETARLO

Las visualizaciones PERSUADEN, así que sé honesto: una nube de palabras muestra frecuencia, no importancia, y sin limpieza léxica se llena de ruido OCR y stopwords (aquí hay una capa de lematización + filtro). El tamaño de fuente no es una medida precisa; para comparar usa barras. Los heatmaps temporales revelan estacionalidad/picos, pero su color depende de la escala elegida — decláralo. Toda figura del paper necesita pie con la fuente de datos y el método; una figura bonita sin método no es evidencia.



Comparativo

Análisis comparativo interno

QUÉ ES

Análisis comparativo interno: contrasta subconjuntos del mismo corpus (por número, sección, periodo) en sus métricas léxicas, temáticas o de tono.

PARA QUÉ SIRVE

Detectar diferencias y evolución dentro del corpus: ¿cambia el vocabulario entre números?, ¿difiere el tono por sección?

QUÉ RESULTADO DA

Tablas y gráficos comparativos lado a lado de los grupos elegidos.

CÓMO INTERPRETARLO

Compara grupos de tamaño parecido: un subconjunto mucho mayor domina las frecuencias absolutas, así que usa proporciones o medidas normalizadas. Una diferencia visible no es necesariamente SIGNIFICATIVA: con pocos documentos puede ser azar; si el paper lo exige, respáldala con un test. Asegúrate de comparar lo comparable (no mezcles publicidad con artículos). Las diferencias más interesantes suelen ser cualitativas (qué palabras cambian), no sólo cuantitativas.



Multi-corpus

Comparación entre proyectos

QUÉ ES

Comparación multi-corpus: contrasta ESTE proyecto con otro distinto (otra revista, otro periodo, otro medio).

PARA QUÉ SIRVE

Situar tu corpus frente a un punto de referencia externo: qué tiene de propio. Estampa frente a otra publicación.

QUÉ RESULTADO DA

Métricas y figuras comparativas entre dos o más corpus.

CÓMO INTERPRETARLO

El riesgo principal es comparar manzanas con naranjas: corpus de distinto tamaño, época, calidad de OCR o criterios de segmentación NO son directamente comparables. Normaliza (proporciones, tasas por mil palabras) y declara las diferencias de origen. Lo que distingue a un corpus de otro puede deberse al objeto de estudio o a un artefacto del procesamiento: descarta lo segundo antes de afirmar lo primero. Bien hecho, el contraste externo es lo que da relieve a tus hallazgos.



Intertexto

Análisis intertextual

QUÉ ES

Análisis intertextual: detecta pasajes que comparten texto o citas entre artículos (la misma noticia republicada, fuentes comunes) por similitud TF-IDF.

PARA QUÉ SIRVE

Rastrear circulación de textos y dependencias entre piezas: qué se copia, qué se cita, qué se reescribe.

QUÉ RESULTADO DA

Pares de artículos con su grado de similitud y los fragmentos compartidos.

CÓMO INTERPRETARLO

Una similitud alta sugiere reutilización, pero distingue cita legítima de fórmula compartida de la época (frases hechas, teletipos): no todo solapamiento es plagio ni copia directa. Fija un umbral y justifícalo: demasiado bajo trae coincidencias triviales, demasiado alto sólo duplicados exactos. El OCR ruidoso BAJA las similitudes reales (errores distintos en cada copia), así que la herramienta subestima la intertextualidad en corpus degradados. Verifica siempre los pares candidatos leyendo los fragmentos.



Metadatos URL

Metadatos desde URL externa

QUÉ ES

Extracción de metadatos desde una URL externa: recupera datos bibliográficos/catalográficos de un recurso en línea.

PARA QUÉ SIRVE

Completar la ficha del corpus o de una fuente con datos estructurados sin teclearlos a mano.

QUÉ RESULTADO DA

Campos de metadatos (título, autor, fecha, identificadores) extraídos del recurso.

CÓMO INTERPRETARLO

Verifica siempre los metadatos recuperados contra la fuente: los catálogos en línea tienen errores y campos ambiguos. Anota la fecha de captura y la URL exacta: el recurso puede cambiar o desaparecer. Estos metadatos alimentan tu citación y tu paquete de publicación, así que un dato erróneo aquí se propaga a la bibliografía final.

Tipografía

Visual y tipografía

QUÉ ES

Análisis visual y tipográfico: examina la materialidad de la página — fuentes, negritas/cursivas, número y disposición de fotos, filetes — más allá del texto.

PARA QUÉ SIRVE

Estudiar el DISEÑO de la prensa ilustrada como objeto: cómo la tipografía y la imagen construyen sentido, no sólo las palabras.

QUÉ RESULTADO DA

Inventario de elementos visuales y rasgos tipográficos por página.

CÓMO INTERPRETARLO

Es el puente entre el análisis textual y la cultura visual del impreso. La detección de fotos/elementos depende de la calidad de imagen: en microfilm saturado de tinta el detector puede dar 0 elementos por el origen, no por error del método; válidalo sobre imágenes limpias. La presencia de negrita/cursiva marca jerarquías editoriales (titulares, destacados) interpretables como énfasis. Para una revista, el análisis de la materialidad gráfica es un aporte distintivo frente a estudios sólo textuales.



Desc. imágenes

Descripción e iconografía de imágenes etiquetadas

QUÉ ES

Descripción e iconografía de imágenes: la IA describe el contenido de las fotos/ilustraciones etiquetadas (qué se ve, quién, qué escena).

PARA QUÉ SIRVE

Hacer BUSCABLE y analizable el componente visual: convertir fotos en texto descriptivo para estudiar la iconografía de la revista.

QUÉ RESULTADO DA

Descripciones textuales por imagen, agregables en un análisis iconográfico del corpus.

CÓMO INTERPRETARLO

Las descripciones son INTERPRETACIONES de un modelo entrenado en imágenes modernas: puede no reconocer personajes, ropa o contextos de 1930, y proyectar categorías actuales. Trátalas como un primer índice a verificar, no como descripción objetiva. Son muy útiles para encontrar y agrupar imágenes (p. ej. todas las que muestran multitudes, retratos, escenas bélicas), pero el análisis iconográfico fino requiere tu mirada experta. Documenta el modelo usado: distintos modelos describen distinto.

Salida y control de calidad

Lo que convierte el análisis en resultados citables, y lo que permite defender su fiabilidad.



Benchmark OCR

Compara rutas de OCR contra un estándar de oro (CER/WER)

QUÉ ES

Evaluación comparativa de las rutas de OCR: transcribe las mismas páginas con varios motores y mide cuánto se aleja cada uno de una transcripción que tú hiciste a mano (el estándar de oro).

PARA QUÉ SIRVE

Justificar con datos qué motor usar, en vez de elegirlo por impresión. Es la respuesta a la pregunta que hace cualquier evaluador: «¿por qué este OCR y no otro?».

QUÉ RESULTADO DA

Una tabla con CER, WER, similitud de Levenshtein normalizada y segundos por página para cada ruta, exportable a CSV o como tabla Markdown lista para pegar en el artículo.

CÓMO INTERPRETARLO

El CER (Character Error Rate) es la métrica principal: es la proporción de caracteres que habría que corregir. Por debajo de 0,05 el texto está casi limpio; hasta 0,10 es explotable para análisis léxico y NER; entre 0,10 y 0,25 exige corrección manual antes de analizar; por encima de 0,25 el texto es inservible y cualquier conclusión que saques de él será ruido. El WER siempre sale más alto que el CER porque un solo carácter mal invalida la palabra entera — es la métrica realista si vas a hacer búsquedas o frecuencias. La similitud normalizada ($1 - \text{CER}$) es la que reportan los papers de HTR, úsala para comparar tus cifras con la literatura: CHURRO reporta 0,823 en impreso histórico. Mira también los segundos por página: una ruta con CER 0,02 que tarda tres minutos por página sirve para construir el estándar de oro, no para procesar mil páginas. Lo habitual es usar la lenta y buena para crear la referencia, y la rápida para el corpus completo. Advertencia metodológica: el estándar de oro debe ser una muestra REPRESENTATIVA (páginas limpias y sucias, con y sin fotograbado), no las mejores; si eliges solo páginas fáciles medirás una calidad que no tendrás en producción.



Reporte

Reporte narrativo (IA)

QUÉ ES

Reporte narrativo con IA: genera un texto que resume e hila los hallazgos del proyecto en prosa académica.

PARA QUÉ SIRVE

Tener un borrador o andamiaje para la sección de resultados/discusión, a partir de las métricas ya calculadas.

QUÉ RESULTADO DA

Un documento narrativo en lenguaje natural con los principales resultados.

CÓMO INTERPRETARLO

Es un BORRADOR asistido, no un resultado: la IA puede redondear cifras, inferir relaciones que los datos no sostienen o inventar matices. Trátalo como un co-autor júnior al que hay que revisar línea por línea contra los datos reales. Útil para vencer la página en blanco y para verbalizar patrones, pero la responsabilidad interpretativa y la verificación factual son tuyas. No cites el reporte como evidencia: cita los datos que lo respaldan.



Dashboard

Dashboard ejecutivo

QUÉ ES

Dashboard ejecutivo: panel con los indicadores clave del corpus (tamaño, entidades, temas, tono, redes) en una sola vista.

PARA QUÉ SIRVE

Tener una fotografía sintética del proyecto para presentaciones, seguimiento y control de calidad.

QUÉ RESULTADO DA

Una vista agregada con cifras y mini-gráficos de las métricas principales.

CÓMO INTERPRETARLO

Es un RESUMEN: cada indicador remite a un análisis más detallado donde se interpreta con rigor; no saques conclusiones sólo del número del dashboard. Úsalo para control de calidad (un conteo de entidades=0 o un corpus de 0 artículos delatan un problema aguas arriba) y para comunicar el alcance del proyecto. Los KPIs orientan, pero el argumento del paper se construye con los análisis específicos, no con el panel.



Validar

Validación humana y semáforo

QUÉ ES

Validación humana y semáforo de calidad: marca cada dato como fiable (verde), dudoso (amarillo) o problemático (rojo) y permite contrastar el etiquetado automático con humano.

PARA QUÉ SIRVE

Garantizar y DOCUMENTAR la fiabilidad de los datos antes de publicar: separar lo confirmado de lo que falta revisar.

QUÉ RESULTADO DA

Un estado de calidad por dato/entidad y métricas de concordancia (acuerdo %, Kappa de Cohen) sobre muestras.

CÓMO INTERPRETARLO

El semáforo prioriza tu esfuerzo de revisión: ataca primero el rojo. El Kappa de Cohen es el dato duro: corrige el acuerdo esperado por azar; valores >0.6 = aceptable, >0.8 = bueno, <0.4 = pobre (tu etiquetado automático no es fiable y hay que mejorarlo). La muestra de validación se extrae con semilla fija para que sea REPRODUCIBLE. Reportar concordancia inter-codificador no es opcional en una revista seria: es lo que separa una afirmación cuantitativa creíble de una impresión. La matriz de confusión te dice DÓNDE falla el método (qué categorías confunde).



Colaborar

Colaboración y trazabilidad

QUÉ ES

Colaboración y trazabilidad: registra quién hizo qué en el proyecto y permite trabajo en equipo con historial.

PARA QUÉ SIRVE

Coordinar varios investigadores y dejar auditable la cadena de decisiones sobre el corpus.

QUÉ RESULTADO DA

Un registro de acciones y contribuciones por persona.

CÓMO INTERPRETARLO

No produce análisis, sino RESPONSABILIDAD: en proyectos colaborativos, saber quién tomó cada decisión (qué criterio de normalización, qué anotación) es esencial para la integridad y para los créditos de autoría. El historial respalda la reproducibilidad: otro investigador puede ver cómo se construyó el dato. Acuerda con tu equipo los criterios ANTES de empezar; el registro documenta, no sustituye, el consenso metodológico.

14 Cuando algo no funciona

La aplicación no abre

Si se lanza desde un acceso directo o un archivo por lotes y no ocurre nada, lo primero a comprobar es la **ruta**: los accesos directos antiguos pueden apuntar a carpetas que se renombraron. Un archivo por lotes bien hecho comprueba que la carpeta existe y avisa en lugar de cerrarse en silencio.

Si se ejecuta desde el código fuente y parece colgado en el primer arranque, puede estar instalando dependencias. Es normal la primera vez.

La ventana se congela

Las operaciones largas corren en segundo plano y la ventana debería seguir respondiendo. Si se congela al cambiar de página en Normalizar o en el Etiquetador, conviene comprobar que la carpeta de trabajo **no esté en una unidad de red o en una carpeta sincronizada en la nube**: cada lectura pasa a ser una consulta remota.

La aplicación guarda en caché local las páginas ya vistas, así que la segunda visita a una página es mucho más rápida que la primera.

El reconocimiento devuelve cero palabras

Es el síntoma clásico de una página de microfilm inclinada. En orden:

1. Etiquetar las zonas y usar la ruta por zonas, que corrige la inclinación y trata cada región por separado.
2. Si sigue sin salir nada, probar Kraken o CHURRO-3B.
3. Si tampoco, es probable que la imagen de origen no tenga información recuperable. Conviene verificarlo con el visor antes de invertir más tiempo.

Un modelo de visión no aparece disponible

El panel indica el motivo en lugar de fallar a mitad de un trabajo. Los motivos habituales son que falte descargar el modelo —hay un botón para ello— o que la biblioteca correspondiente no esté instalada, en cuyo caso el propio mensaje indica qué hacer.

El proyecto de ayer no aparece

Está en el botón grande de continuar de la pantalla de bienvenida, con su fecha de última modificación. La lista de recientes no repite el proyecto actual. Si el nombre despista, conviene recordar que corresponde a la fecha de **creación**, no a la del último trabajo.

15 Glosario

CER (*character error rate*). Proporción de caracteres que habría que corregir en una transcripción automática respecto de una de referencia. Es la métrica principal para evaluar reconocimiento de texto.

Corpus. El conjunto de textos sobre el que se trabaja, con sus metadatos. En esta aplicación, un corpus se organiza en números, páginas y artículos.

Entidad nombrada. Una persona, lugar, organización, fecha, obra o evento mencionado en el texto. Identificarlas permite pasar del análisis de palabras al análisis de actores.

Estándar de oro. Transcripción hecha a mano que se toma como verdad para medir el error de los métodos automáticos.

HTR (*handwritten text recognition*). Reconocimiento de texto manuscrito. Se distingue del OCR clásico, pensado para impresos.

Kappa de Cohen. Medida de acuerdo entre dos codificadores que corrige el acuerdo esperado por azar. Por encima de 0,6 se considera aceptable; por debajo de 0,4, pobre.

Lematizar. Reducir cada palabra a su forma de diccionario. Útil para contar frecuencias, destructivo para estudiar variación ortográfica histórica.

OCR (*optical character recognition*). Reconocimiento óptico de caracteres: convertir la imagen de un texto impreso en texto codificado.

Orden de lectura. La secuencia en que deben leerse las zonas de una página para reconstruir el discurso. En maquetación a varias columnas no coincide con el orden de arriba abajo.

TEI. *Text Encoding Initiative*, el estándar de codificación de textos en humanidades digitales. Permite marcar estructura, entidades y variantes de forma interoperable.

Tokenizar. Dividir un texto en unidades mínimas de análisis, normalmente palabras. Es el primer paso de casi cualquier procesamiento lingüístico.

Wikidata. Base de conocimiento colaborativa que asigna un identificador único a cada entidad. Enlazar a ella convierte una mención en un dato citable y comparable entre proyectos.

Zona. Región rectangular de una página con una tipología asignada: artículo, título, pie de foto, fotografía, publicidad, filete. El reconocimiento trabaja sobre las zonas que llevan texto.

Manual generado desde el código fuente de Bashkar Station. La referencia de paneles procede de `core/guia_modulos.py` , la misma fuente que alimenta la ayuda dentro de la aplicación.

Bashkar Station es software libre bajo licencia Apache 2.0.
github.com/fabianguilla-pixel/Bashkar-Station